

BÁO CÁO NGHIÊN CỨU THỰC NGHIỆM VÀ KỸ THUẬT

NGHIÊN CỨU CÁC PHƯƠNG PHÁP ƯỚC LƯỢNG DOUBLY ROBUST CATE CHO BÀI TOÁN UPLIFT MODELING

*So sánh DR-Learner và Double Machine Learning (DML) định hướng nâng cấp pipeline cá nhân
hóa khuyến mãi trên dữ liệu Lazada*

Người thực hiện:

Hà Trung Kiên

Lĩnh vực: *Data Science & Causal ML*

Thông tin dự án:

Dự án: *final-lazada*

Tháng 8 năm 2026

Mục lục

Tóm tắt thực thi (Executive Summary)	2
1 Giới thiệu và đặt vấn đề nghiên cứu	2
1.1 Bài toán cá nhân hóa khuyến mãi tại Lazada	2
1.2 Sự khác biệt cốt lõi: phân loại thông thường và uplift modeling	3
2 Thách thức dữ liệu và thiên vị chọn lọc	3
2.1 Observational Data vs. RCT Data	3
2.2 Đo lường thiên vị chọn lọc bằng chỉ số SMD	4
2.3 Các giả định suy luận nhân quả cốt lõi	4
3 Cơ chế hoạt động của các mô hình CATE	4
3.1 Nhóm mô hình cơ sở	4
3.1.1 S-Learner (Single Learner)	4
3.1.2 T-Learner (Two Learners)	4
3.2 Họ mô hình DR-Learner	4
3.2.1 Quy trình ước lượng	5
3.2.2 Tính chất doubly robust	5
3.3 Họ mô hình Double Machine Learning	5
3.3.1 Nguyên lý partialling-out	6
3.3.2 Các biến thể DML trong nghiên cứu	6
4 Quy trình thực nghiệm Data Science	6
4.1 Notebook 01: 01_eda.ipynb — phân tích và chia dữ liệu	6
4.2 Notebook 02: 02_feature_engineering.ipynb — kỹ nghệ đặc trưng	6
4.3 Notebook 03: 03_model_tuning.ipynb — tuning và overlap	6
4.4 Notebook 04: 04_benchmark_evaluation.ipynb — đánh giá và ablation	7
5 Kiến trúc triển khai production và hạ tầng MLOps	7
5.1 Các thành phần hạ tầng cốt lõi	8
6 Kết quả thực nghiệm và thảo luận	9
6.1 Benchmark trên tập RCT-holdout	9
6.2 Thảo luận trung thực về mặt khoa học	9
7 Kết luận và hướng phát triển	9

Tóm tắt thực thi (Executive Summary)

Báo cáo này trình bày nghiên cứu thực nghiệm về các phương pháp ước lượng **Conditional Average Treatment Effect (CATE)** có đặc tính **doubly robust** cho bài toán cá nhân hóa khuyến mãi (uplift modeling) trên dữ liệu Lazada, gồm 926 669 quan sát và 181 669 mẫu từ thử nghiệm ngẫu nhiên có đối chứng (RCT). Nghiên cứu so sánh DR-Learner [1], các biến thể Double Machine Learning (LinearDML, NonParamDML và CausalForestDML) [2], cùng hai mô hình cơ sở S-Learner và T-Learner.

Các kết quả và đóng góp chính:

1. **Thiết kế thực nghiệm:** Chia dữ liệu cố định thành `Train` (80% observational), `Val` (20% observational), `RCT-select` (50% RCT) và `RCT-holdout` (50% RCT). Tập `RCT-holdout` chỉ được dùng ở bước đánh giá cuối.
2. **Lựa chọn mô hình:** DR-Learner được chọn trên `RCT-select` theo Qini Score và vượt có ý nghĩa thống kê 2 trong 5 đối thủ. Trên `RCT-holdout`, mô hình đạt Qini 0.0232 với khoảng tin cậy bootstrap 95% $[-0.0007, 0.0483]$. Khoảng này chứa 0 nên chưa đủ bằng chứng để khẳng định khả năng xếp hạng tốt hơn ngẫu nhiên ở mức ý nghĩa 5%.
3. **Ablation và feature contract:** Trong 76 đầu vào mô hình, 62 đặc trưng sống tái tạo đúng dự đoán của mô hình trên phép kiểm chứng đã thực hiện; luồng nguồn cần 59 cột gốc để cung cấp 55 cột trực tiếp và tính 7 đặc trưng dẫn xuất.
4. **Đóng gói và triển khai:** Đóng gói model artifact, feature contract và mô tả kiến trúc MLOps gồm Airflow, Redis, MinIO và FastAPI. Mức độ hoàn thiện của từng thành phần được đánh giá riêng thay vì xem toàn bộ kiến trúc là một khối đã hoàn tất.

1 Giới thiệu và đặt vấn đề nghiên cứu

1.1 Bài toán cá nhân hóa khuyến mãi tại Lazada

Trong các nền tảng thương mại điện tử lớn như Lazada, ngân sách dành cho các chương trình khuyến mãi (voucher giảm giá, freeship) chiếm một tỷ trọng rất lớn trong chi phí vận hành. Phương pháp phát voucher đại trà hoặc phát dựa trên các quy tắc thủ công (heuristics) thường dẫn đến việc lãng phí ngân sách nghiêm trọng do tặng nhầm đối tượng.

Khung uplift marketing thường mô tả khách hàng bằng **bốn nhóm phản ứng tiềm ẩn** dựa trên hai kết quả đối chứng khi có và không có voucher. Đây là cách diễn giải ở cấp độ potential outcomes; từ dữ liệu quan sát, ta không thể biết đồng thời cả hai kết quả của cùng một cá nhân.



Hình 1: Phân loại 4 nhóm khách hàng theo phản ứng can thiệp (Treatment Response).

1.2 Sự khác biệt cốt lõi: phân loại thông thường và uplift modeling

- **Phân loại truyền thống:** Mô hình dự đoán xác suất $\mathbb{P}(Y = 1 \mid X)$, tức “khách hàng có mua hàng hay không?”. Nhóm có xác suất mua cao có thể gồm nhiều khách hàng vốn đã mua mà không cần voucher, nên thứ hạng này không trực tiếp tối ưu hiệu quả can thiệp.
- **Uplift modeling/CATE estimation:** Mô hình ước lượng hiệu ứng can thiệp trung bình có điều kiện:

$$\tau(X) = \mathbb{E}[Y^{(1)} - Y^{(0)} \mid X].$$

Dưới các giả định consistency, conditional exchangeability và overlap, với kết quả nhị phân ta nhận dạng được

$$\tau(X) = \mathbb{P}(Y = 1 \mid T = 1, X) - \mathbb{P}(Y = 1 \mid T = 0, X).$$

Trong đó $T \in \{0, 1\}$ biểu thị việc nhận voucher và $Y \in \{0, 1\}$ biểu thị hành vi mua hàng. Giá trị $\tau(X) > 0$ cho biết hiệu ứng trung bình dương trong nhóm có đặc trưng X ; nó không xác định chắc chắn kiểu phản ứng của từng cá nhân.

2 Thách thức dữ liệu và thiên vị chọn lọc

2.1 Observational Data vs. RCT Data

Bộ dữ liệu Lazada trong nghiên cứu gồm hai nguồn có cơ chế gán treatment khác nhau:

1. **Dữ liệu quan sát:** 926 669 dòng, sau khi chia thành `train` và `val`. Cơ chế phát voucher lịch sử tạo ra khác biệt đáng kể về các đặc trưng nền giữa nhóm treatment ($T = 1$) và control ($T = 0$).
2. **Dữ liệu RCT:** 181 669 dòng. Xác suất gán voucher theo thiết kế là $e(X) = 0.5$. Ngẫu nhiên hóa cân bằng hai nhóm theo kỳ vọng; trong mẫu hữu hạn vẫn có thể tồn tại sai khác ngẫu nhiên nhỏ.

2.2 Đo lường thiên vị chọn lọc bằng chỉ số SMD

Chỉ số **Standardized Mean Difference (SMD)** được dùng để đo mức chênh lệch giữa nhóm $T = 1$ và $T = 0$ trên từng đặc trưng X_j :

$$\text{SMD}(X_j) = \frac{\bar{X}_{j,T=1} - \bar{X}_{j,T=0}}{\sqrt{(s_{j,T=1}^2 + s_{j,T=0}^2) / 2}}.$$

Ngưỡng thường dùng để cảnh báo mất cân bằng là $|\text{SMD}| > 0.1$. Dữ liệu quan sát có nhiều đặc trưng vượt ngưỡng này, trong khi SMD của RCT tập trung gần 0 hơn.

2.3 Các giả định suy luận nhân quả cốt lõi

Để nhận dạng CATE từ dữ liệu quan sát, nghiên cứu dựa trên các giả định sau:

1. **Consistency và SUTVA:** treatment được định nghĩa nhất quán, không có nhiều phiên bản treatment không được mô hình hóa, và kết quả của một khách hàng không bị ảnh hưởng bởi treatment của khách hàng khác.
2. **Conditional exchangeability (unconfoundedness):** $(Y^{(1)}, Y^{(0)}) \perp\!\!\!\perp T \mid X$. Sau khi điều kiện hóa theo X , không còn biến nhiễu chung chưa quan sát giữa treatment và outcome.
3. **Overlap/positivity:** tồn tại $\eta > 0$ sao cho $\eta \leq e(X) \leq 1 - \eta$ trên quần thể mục tiêu.

3 Cơ chế hoạt động của các mô hình CATE

Nghiên cứu tiến hành cài đặt và so sánh 6 họ mô hình ước lượng CATE:

3.1 Nhóm mô hình cơ sở

3.1.1 S-Learner (Single Learner)

S-Learner sử dụng **một mô hình học máy** $\mu(X, T)$ để dự đoán Y , trong đó treatment T được đưa vào như một đặc trưng:

$$\hat{\tau}_S(X) = \hat{\mu}(X, T = 1) - \hat{\mu}(X, T = 0).$$

- **Ưu điểm:** Đơn giản và tận dụng toàn bộ dữ liệu trong một mô hình.
- **Hạn chế:** Khi tín hiệu treatment yếu hoặc không gian đặc trưng lớn, regularization có thể khiến mô hình ít sử dụng T , làm co ước lượng hiệu ứng về 0.

3.1.2 T-Learner (Two Learners)

T-Learner huấn luyện hai mô hình outcome riêng theo treatment:

$$\hat{\mu}_1(X) = \text{Model}_1(Y \mid X, T = 1), \quad \hat{\mu}_0(X) = \text{Model}_0(Y \mid X, T = 0),$$

$$\hat{\tau}_T(X) = \hat{\mu}_1(X) - \hat{\mu}_0(X).$$

- **Ưu điểm:** Cho phép hai bề mặt outcome khác nhau giữa hai nhóm.
- **Hạn chế:** Nếu hai nhóm mất cân bằng hoặc overlap kém, mô hình ở vùng ít dữ liệu có phương sai và sai số ngoại suy cao; sai số của cả hai outcome model cùng truyền vào hiệu số CATE.

3.2 Họ mô hình DR-Learner

DR-Learner là phương pháp hai giai đoạn dựa trên pseudo-outcome doubly robust [1, 4].

3.2.1 Quy trình ước lượng

1. **Ước lượng nuisance:** Dùng cross-fitting K -fold để ước lượng propensity score $\hat{e}(X) = \mathbb{P}(T = 1 | X)$ và hai outcome regression $\hat{\mu}_1(X) = \mathbb{E}[Y | T = 1, X]$, $\hat{\mu}_0(X) = \mathbb{E}[Y | T = 0, X]$.
2. **Tạo pseudo-outcome:**

$$\tilde{Y}_i = \hat{\mu}_1(X_i) - \hat{\mu}_0(X_i) + \frac{T_i\{Y_i - \hat{\mu}_1(X_i)\}}{\hat{e}(X_i)} - \frac{(1 - T_i)\{Y_i - \hat{\mu}_0(X_i)\}}{1 - \hat{e}(X_i)}. \quad (1)$$

3. **Hồi quy CATE cuối:** Hồi quy $\tilde{Y}$ theo X , chẳng hạn bằng LightGBM:

$$\hat{\tau}_{DR}(X) = \text{Regress}(\tilde{Y} | X).$$

3.2.2 Tính chất doubly robust

[Doubly Robust Property] Dưới consistency, conditional exchangeability và positivity, kỳ vọng điều kiện $\mathbb{E}[\tilde{Y} | X]$ bằng CATE $\tau(X)$ nếu ít nhất một trong hai thành phần nuisance sau được đặc tả đúng: outcome regression $\mu_t(X)$ hoặc propensity score $e(X)$.

Chứng minh. Xét hai trường hợp độc lập:

Trường hợp 1: outcome model đúng, propensity model sai. Khi outcome model đúng, phần dư có kỳ vọng điều kiện bằng 0:

$$\mathbb{E}[Y - \mu_1(X) | T = 1, X] = 0, \quad \mathbb{E}[Y - \mu_0(X) | T = 0, X] = 0.$$

Với mọi ước lượng propensity dương $\hat{e}^*(X)$, ta có

$$\begin{aligned} \mathbb{E}[\tilde{Y} | X] &= \mu_1(X) - \mu_0(X) + \frac{\mathbb{E}[T\{Y - \mu_1(X)\} | X]}{\hat{e}^*(X)} - \frac{\mathbb{E}[(1 - T)\{Y - \mu_0(X)\} | X]}{1 - \hat{e}^*(X)} \\ &= \mu_1(X) - \mu_0(X) = \tau(X). \end{aligned}$$

Hai số hạng hiệu chỉnh có kỳ vọng bằng 0 dù propensity model bị đặc tả sai.

Trường hợp 2: propensity model đúng, outcome model sai. Gọi $\mu_t^*(X)$ là outcome model có thể bị đặc tả sai. Khi propensity model đúng, conditional exchangeability cho

$$\mathbb{E}\left[\frac{T\{Y - \mu_1^*(X)\}}{e(X)} \middle| X\right] = \mu_1(X) - \mu_1^*(X),$$

và tương tự cho nhóm control. Do đó

$$\begin{aligned} \mathbb{E}[\tilde{Y} | X] &= \mu_1^*(X) - \mu_0^*(X) + \{\mu_1(X) - \mu_1^*(X)\} - \{\mu_0(X) - \mu_0^*(X)\} \\ &= \mu_1(X) - \mu_0(X) = \tau(X). \end{aligned}$$

Sai số của outcome model được bù bởi hai số hạng hiệu chỉnh khi propensity model đúng. $\square$

3.3 Họ mô hình Double Machine Learning

DML giảm ảnh hưởng bậc nhất của sai số ước lượng nuisance bằng Neyman orthogonality và cross-fitting [2].

3.3.1 Nguyên lý partialling-out

Với treatment nhị phân và mô hình outcome có điều kiện $\mathbb{E}[Y \mid X, T] = \mu_0(X) + T\tau(X)$, đặt $m(X) = \mathbb{E}[Y \mid X]$ và $e(X) = \mathbb{E}[T \mid X]$. Khi đó

$$Y - m(X) = \tau(X)\{T - e(X)\} + \varepsilon, \quad \mathbb{E}[\varepsilon \mid X, T] = 0.$$

Trong thực nghiệm, các phần dư được xây dựng từ dự đoán ngoài fold: $\tilde{Y}_{res} = Y - \hat{m}(X)$ và $\tilde{T}_{res} = T - \hat{e}(X)$.

3.3.2 Các biến thể DML trong nghiên cứu

- **LinearDML**: Mô hình hóa CATE theo dạng tuyến tính $\tau(X) = X^\top \theta$.
- **NonParamDML**: Cho phép final stage phi tham số để biểu diễn bề mặt CATE linh hoạt hơn.
- **CausalForestDML**: Dùng causal forest với honest splitting. Khoảng tin cậy chỉ có diễn giải thống kê hợp lệ khi các giả định và điều kiện tiệm cận của phương pháp được đáp ứng.

4 Quy trình thực nghiệm Data Science

Dự án thiết kế luồng xử lý 4 Notebooks tuần tự, nối với nhau qua tệp Parquet và JSON:

4.1 Notebook 01: 01_eda.ipynb — phân tích và chia dữ liệu

- Phát hiện và loại bỏ các cột hằng số và trùng lặp.
- Thiết kế phép chia phân tầng cố định thành bốn tập:

```
full_trainset.csv (926669 dòng, observational)
|-- Train (80%, xấp xỉ 741k): huấn luyện mô hình
`-- Val (20%, xấp xỉ 185k): tính chính siêu tham số

full_testset.csv (181669 dòng, RCT)
|-- RCT-select (50%, xấp xỉ 91k): chọn mô hình
`-- RCT-holdout (50%, xấp xỉ 91k): đánh giá cuối
```

Nguyên tắc sử dụng tập RCT-holdout

Tập `RCT-holdout` bị khóa hoàn toàn trong suốt quá trình phát triển mô hình. Mọi quyết định về siêu tham số, chọn mô hình hay rút gọn đặc trưng đều phải hoàn tất trước khi mở tập này.

4.2 Notebook 02: 02_feature_engineering.ipynb — kỹ nghệ đặc trưng

Tạo 7 đặc trưng dẫn xuất từ dữ liệu lịch sử. Sau bước làm sạch, đầu vào mô hình gồm **76 đặc trưng**: 69 cột gốc và 7 cột dẫn xuất.

4.3 Notebook 03: 03_model_tuning.ipynb — tuning và overlap

- **Overlap**: Loại khỏi metric các quan sát có $e(X)$ nằm ngoài $[\alpha, 1 - \alpha]$, với $\alpha = 0.071$ được xác định theo quy tắc Crump và cộng sự [3]. Estimand của metric vì vậy thuộc quần thể overlap, không phải toàn bộ tập validation.
- **Winsorization**: Giới hạn pseudo-outcome tại phân vị 0.5% và 99.5% để ổn định metric xếp hạng; biến đã winsorize không được dùng để báo cáo mức ATE.


- **Optuna:** Chạy 66 trial cho sáu mô hình trên `Val`, tối ưu DR-AUUC và lưu lịch sử vào SQLite `mlflow.db`.

4.4 Notebook 04: `04_benchmark_evaluation.ipynb` — đánh giá và ablation

- Huấn luyện lại sáu mô hình trên 926 669 dòng từ `Train` và `Val`.
- Chọn DRLearner trên `RCT-select`; mô hình này vượt có ý nghĩa thống kê 2 trong 5 đối thủ theo phép bootstrap cặp.
- Ablation cho thấy 62 đặc trưng sống cho dự đoán trùng bản 76 đặc trưng trong phép kiểm chứng đã thực hiện. Luồng phục vụ cần 59 cột nguồn để cung cấp 55 cột trực tiếp và tính 7 cột dẫn xuất; 14 đầu vào còn lại được điền giá trị mặc định theo feature contract.
- Trên `RCT-holdout`, DRLearner đạt Qini 0.0232 với khoảng tin cậy bootstrap 95% $[-0.0007, 0.0483]$. ATE của toàn tập `RCT-holdout` là 0.00376, tương đương 0.376 pp với khoảng tin cậy $[0.137, 0.615]$ pp. Uplift tại top 10%/20%/30% lần lượt là 1.42 pp, 1.31 pp và 0.96 pp.

5 Kiến trúc triển khai production và hạ tầng MLOps

Dưới đây là kiến trúc mục tiêu cho hệ thống phục vụ dự đoán gần thời gian thực. Khối Data Science bàn giao model artifact và feature contract; khối Data Engineering chịu trách nhiệm tính, lưu và phục vụ đặc trưng cũng như quản lý vòng đời mô hình.



Hình 2: Sơ đồ phân chia luồng công việc giữa Data Science (DS) và Data Engineering (DE).

5.1 Các thành phần hạ tầng cốt lõi

1. **Feature contract** (`feature_contract.json`): quy định thứ tự 76 đầu vào mô hình, 59 cột nguồn cần lấy từ hệ thống, công thức cho 7 cột dẫn xuất và giá trị mặc định cho các cột không được phục vụ trực tiếp.
2. **Airflow ETL**: tính các đặc trưng offline theo cửa sổ 7 và 30 ngày, sau đó đồng bộ dữ liệu sang feature store.
3. **Redis feature store**: lưu dữ liệu key-value với TTL và cơ chế fallback khi pipeline hằng ngày gặp sự cố.
4. **MinIO model registry**: lưu các phiên bản model artifact và con trỏ phiên bản đang được phê duyệt.
5. **FastAPI service và model loader**: dựng vector đúng feature contract, thực hiện suy luận và nạp phiên bản mới mà không cần dừng toàn bộ dịch vụ. Mục tiêu độ trễ cần được báo cáo kèm môi trường và tải kiểm thử.

6 Kết quả thực nghiệm và thảo luận

6.1 Benchmark trên tập RCT-holdout

Mô hình	Qini	AUUC	Uplift@10% (pp)	Uplift@20% (pp)
DRLearner	0.02324	0.02541	1.418	1.310
SLearner	0.02253	0.02420	1.202	0.727
CausalForestDML	0.01901	0.02048	1.461	1.044
NonParamDML	0.01732	0.01892	1.471	1.174
LinearDML	0.01534	0.01667	0.852	0.648
TLearner	0.01482	0.01600	1.287	0.722

Bảng 1: Kết quả so sánh các mô hình CATE trên tập RCT-holdout. DRLearner được in đậm vì đã được chọn trước đó trên RCT-select, không phải vì được chọn lại trên RCT-holdout.

ATE của toàn bộ RCT-holdout là 0.00376, tương đương 0.376 pp với khoảng tin cậy 95% [0.137, 0.615] pp. Đây là thống kê của dữ liệu RCT, không phải metric riêng của từng mô hình. CausalForestDML được huấn luyện trên mẫu con nhỏ hơn nên kết quả của mô hình này không hoàn toàn ngang hàng về cỡ dữ liệu.

6.2 Thảo luận trung thực về mặt khoa học

- **Khoảng tin cậy chứa 0:** Khoảng tin cậy bootstrap 95% của Qini cho DRLearner là $[-0.0007, 0.0483]$. Vì vậy chưa đủ bằng chứng để bác bỏ mức xếp hạng ngẫu nhiên ở mức ý nghĩa 5%.
- **Thứ hạng không tái lập mạnh:** Tương quan hạng Spearman giữa RCT-select và RCT-holdout là 0.2571. Chênh lệch giữa các mô hình vì vậy cần được xem là chưa ổn định trên hai nửa RCT.
- **Diễn giải vận hành:** Uplift dương ở một phân khúc chưa đủ để quyết định phát voucher. Ngưỡng triển khai còn phải tính đến chi phí voucher, biên lợi nhuận, năng lực chiến dịch và độ bất định của ước lượng.

7 Kết luận và hướng phát triển

Nghiên cứu đã xây dựng một quy trình có thể tái lập từ EDA, kỹ nghệ đặc trưng, tuning, lựa chọn mô hình đến đóng gói artifact và đặc tả kiến trúc phục vụ. DRLearner được chọn theo quy trình định trước trên RCT-select và có Qini cao nhất trong bảng holdout, nhưng khoảng tin cậy chứa 0 và thứ hạng giữa hai nửa RCT tái lập yếu. Vì vậy kết luận phù hợp là DRLearner là **mô hình được chọn cho vòng triển khai thử nghiệm**, chưa phải mô hình được chứng minh tối ưu một cách tổng quát.

Tính chất doubly robust làm giảm sự phụ thuộc vào việc cả hai nuisance model đều đúng, nhưng không tự khắc phục vi phạm overlap, hidden confounding, sai lệch đo lường hoặc dịch chuyển phân phối. Các rủi ro này cần tiếp tục được giám sát trong thử nghiệm trực tuyến.

Hướng phát triển tiếp theo:

1. Đánh giá policy value có tính chi phí và kiểm chứng bằng A/B test trước khi mở rộng phạm vi phát voucher.
2. Thu thập thêm đặc trưng ý định gần thời gian thực và giám sát overlap, calibration, drift cùng hiệu quả theo phân khúc.
3. Chỉ thử representation learning khi có giả thuyết và protocol đánh giá định trước; so sánh với baseline đơn giản để tránh tăng độ phức tạp mà không cải thiện khả năng khái quát.

Tài liệu

- [1] Kennedy, E. H. (2020). Optimal doubly robust estimation of heterogeneous causal effects. *arXiv preprint arXiv:2004.14497*.
- [2] Chernozhukov, V., et al. (2018). Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal*, 21(1), C1–C68.
- [3] Crump, R. K., et al. (2009). Dealing with limited overlap in estimation of average treatment effects. *Biometrika*, 96(1), 187–199.
- [4] Robins, J. M., et al. (1994). Estimation of regression coefficients when some regressors are not always observed. *Journal of the American Statistical Association*, 89(427), 846–866.